マイクロコントローラ上で動作する較正不要脳波デコーダの開発

広尾学園高等学校　早川智晴・国立情報学研究所　杉山麿人

次世代科学技術チャレンジプログラム 情報科学の達人 プログラム

大学共同利用機関法人 情報・システム研究機構 国立情報学研究所 National Institute of Informatics

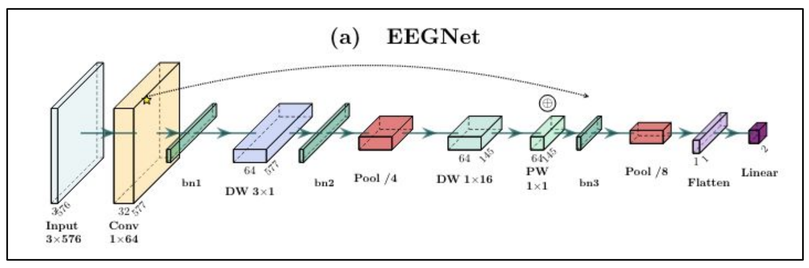
HIROO GAKUEN

要旨

脳卒中などにより、考える力を保ったまま意思を伝える手段を失う人は世界に数多くいる。こうした人を支援する**ブレイン・コンピュータ・インターフェース（BCI）**のうち、**脳波（EEG）**を用いるものでは、EEGを分類するCNNが装着機器に載せづらい計算コストと、使うたびに正解ラベル（どの動作を思い浮かべたか）付きのデータを取り直す較正の負担という二つの課題により、実用化が制約されている。
本研究は、これらの課題に対する既存手法に共通点があることに着目した。計算コストを下げるための**構造化枝刈り**によるモデル圧縮も、正解ラベルを使わずに較正を行う**テスト時適応（AdaBNなど）**も、CNNの**バッチ正規化層**が保持する**統計量（平均と標準偏差）**を変化させる。さらに、枝刈りによって統計量が変化するバッチ正規化層は**ノード間の接続情報だけ**から機械的に判定でき、その層の統計量を正解ラベルなしの試行で更新することで**精度の低下を抑えられる**ことを実験的に示した。

背景

- 脳卒中・筋萎縮性側索硬化症（ALS）・脊髄損傷などにより、考える力を保ったまま、意思を外に出す手段だけを失う人は世界に数多くいる[1,2]
- 頭蓋内に電極を埋める侵襲型に対し、頭皮に貼るだけの**非侵襲型BCI（脳波・EEG）**は手術が要らず、安全で安価。そのため広く研究されている[3]
- 非侵襲型BCIは装着したまま日常生活を送る機器にできる。ただし信号は弱く雑音が多いため、判別には学習ベースのデコーダが必要になる。EEGNet[4] などのCNNが標準[4,5]



❑ 本研究で取り組んだ課題

1. **モデルの計算コスト**
2. **正解ラベル（どの動作を思い浮かべたか）付きのデータを計り直す較正の負担**

❑ 先行研究

1. **計算コスト**
   →圧縮（軽量化）があり、要らないフィルタを重みごと削除する枝刈りが代表である。
2. **較正の負担**
   →ラベルなしで使用時のデータにモデルを合わせ直すTest-Time Adaptation（TTA）がある。AdaBNやTENTが代表である。[7, 8]

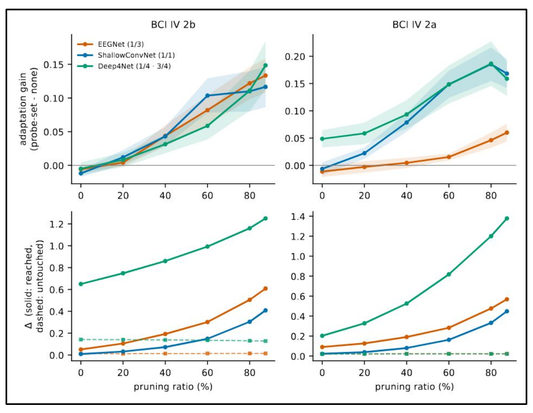
両者を同時に課した設定は十分に検証されていない

提案手法

❑ 圧縮と再較正の手順を構築

データセット： BCI Competition IV 2a/2b
モデル： EEGNet, ShallowConvNet, Deep4Net

1. 配備先の機器に収まる削減率を決め、対象層を選び、その層から重要度の低いフィルタを削除する。
2. 枝刈りの影響が届く正規化層（到達層）を、ノード間の接続情報だけから判定する。
3. 重みを 8 ビット整数に量子化する。
4. 使用時に、目標セッションのラベルなし 16 試行を 1 回実施し、到達層を更新する。
5. 再較正したモデルで推論する。



枝刈り率が高いほど、再較正によって精度低下を抑える効果が大きくなった。

❑ 原理

バッチ正規化層は以下を出力する

$$y = \gamma \frac{x - \mu_s}{\sigma_s} + \beta$$

→ 使用時は学習時の平均と標準偏差と異なり以下へずれる

$$\mathbb{E}[y] = \beta + \gamma \frac{\mu_t - \mu_s}{\sigma_s}, \qquad \mathrm{SD}[y] = |\gamma| \frac{\sigma_t}{\sigma_s}$$

この外れを |γ| を単位として測った二乗和を記録のずれの尺度とする。

$$\Delta = \left(\frac{\mu_t - \mu_s}{\sigma_s}\right)^2 + \left(\frac{\sigma_t}{\sigma_s} - 1\right)^2$$

→ 使用時のデータから μt、σt を測って記録を置き換えるAdaBN [7] の操作（再較正）

$$\hat{\mu}_c = \frac{S_c}{NT}, \qquad \hat{\sigma}_c^2 = \frac{Q_c}{NT} - \hat{\mu}_c^2$$

バッチ正規化層を通る標準偏差と平均を更新することによって枝刈りとセッション・使用者の分布変化を補正する

❑ 再較正するバッチ正規化層の判定

各正規化層の統計量が枝刈りの影響を受けるかを機械的に判定し、影響を受ける層（到達層）のみを再較正する仕組みを構築した。

①固定した入力を枝刈り前のモデルに通して各正規化層の直前の値 aℓ を記録する
②枝刈り対象のフィルタを 1 つだけゼロにして同じ入力で a'ℓ を記録する
③ゼロ化で自明に変わるチャネルを除いて a'ℓ≠aℓ となる層を選ぶ

アーキテクチャ	密	再較正なし	最初の層	無作為	到達層	全層
EEGNet（1 ／ 3 層）	0.833	0.710	0.692	0.726	**0.788**	0.788
ShallowConvNet（1 ／ 1 層）	0.833	0.704	0.779	0.779	0.779	0.779
Deep4Net（1 ／ 4 層）	0.798	0.536	0.537	0.609	**0.781**	0.780

到達層だけを再較正した精度は全層を再較正した場合と変わらなかった。

実験 ①

❑ 既存手法との比較

87.5%枝刈りした同一の EEGNet に対し、**適応の方法**だけを変えて検証した。

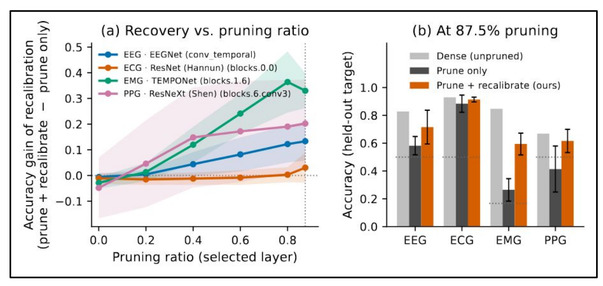
手法	ラベル	逆伝播	計算量	状態量	活性	精度 2b	精度 2a
適応なし	不要	不要	0	0 B	—	0.622*	0.350*
TENT（置換なし）	不要	必要	265 M	4,256 B	167 kB	0.651*	0.369
TENT（保持で選択）	不要	必要	274 M	4,256 B	167 kB	0.752	0.458
AdaBN（全 3 層）	不要	不要	8.8 M	608 B	36 kB	0.754	0.462
本手法（1 層）	不要	不要	8.8 M	512 B	36 kB	0.752	0.463

1. **TENT** [8] は、出力のエントロピーが小さくなるように正規化層のパラメータを**誤差逆伝播**で更新する手法
2. **Euclidean Alignment（EA）**[11] はセッションごとに試行の共分散行列の平均を求め、その −1/2 乗を各試行に掛ける**前処理**の手法

- 精度は**全層のAdaBNともTENTとも変わらず**、差はそれぞれで有意でない。
- **EAは適応なしと変わらなかった。**
- 同じ精度を**TENTの約30 分の 1 の計算量**と**約5分の1の活性メモリ**で得られる。

❑ 他の生体信号への一般化

心電図、筋電図、脈波で同じ測定を行った。各信号には、その分野で**標準的なモデル**を論文の記載に基づいて再実装した。[12, 13, 14]



三つの信号のすべてで、枝刈り率が高いほど再較正の効果が大きくなった。

→ 生体信号処理のモデルを含め、**バッチ正規化層を持つ CNN 一般で成り立つ**と考えられる。

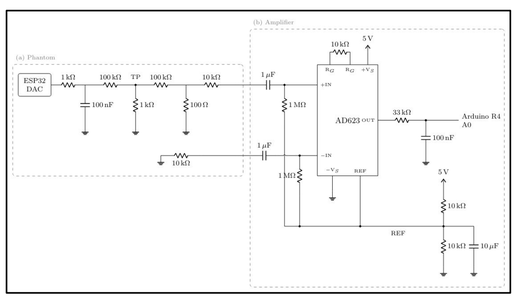
実験 ②

❑ Arduino UNO R4 WiFiで実装

項目	密・32 ビット	87.5% 枝刈り＋8 ビット重み
重み容量	37.8 kB	3.1 kB
Flash 使用量	—	69,720 B（26%）
活性のピーク	440 kB（逐次で 44.5 kB）	13,284 B
SRAM 使用量	逐次でも 54.4 kB	22,080 B（67%）
実装の可否	動作しない	**動作する**
推論時間（1 試行）	—	443.8 ms（425.4〜477.3）
再較正（16 試行、計算のみ）	—	5.96 s（0.372 s ／試行）
精度（再較正なし → 16 試行）	—	0.606 → **0.725**
PyTorch との判定の一致	—	24,776 回すべて

- 密なモデルは、逐次計算にしても 32 kBに**収まらなかった**。
- 基板の上での再較正は**精度を0.61から0.73に上げた。**

❑ 信号経路での確認



増幅回路とファントムを自作した。検証では 1 試行を再生して記録し、EEGNet によって**正しく判別された**。

結論

①再較正による修復の効果が**枝刈り率とともに大きくなる**ことを実験的に示した。
②バッチ正規化層の記録が壊れる層を**ノード間の接続情報から判定する**手続きを構築した。
③同じ仕組みが心電図などの生体信号処理のCNNでも成り立つことを示した。

今後の展望

1. 分布の統計量を明示的に持たない LayerNorm を用いる **Transformer で枝刈り後のずれをどう補正するか** が課題である。
2. 研究室や病院にある研究用の増幅器や電極でこの手法を実際に使ってもらい、**現実の環境での有効性を確かめる**。

参考文献

[1] Feigin, V. L., et al. Lancet Neurol. 20(10), 795–820, 2021.
[2] Chaudhary, U., et al. Nat. Rev. Neurol. 12(9), 513–525, 2016.
[3] Edelman, B. J., et al. IEEE Rev. Biomed. Eng. 18, 26–49, 2025.
[4] Lawhern, V. J., et al. J. Neural Eng. 15(5), 056013, 2018.
[5] Schirrmeister, R. T., et al. Hum. Brain Mapp. 38(11), 5391–5420, 2017.
[6] Li, H., et al. ICLR, 2017.
[7] Li, Y., et al. Pattern Recognit. 80, 109–117, 2018.
[8] Wang, D., et al. ICLR, 2021.
[9] Tangermann, M., et al. Front. Neurosci. 6, 55, 2012
[10] Ioffe, S. & Szegedy, C. ICML, 448–456, 2015..
[11] He, H. & Wu, D. IEEE Trans. Biomed. Eng. 67(2), 399–410, 2020.
[12] Hannun, A. Y., et al. Nat. Med. 25(1), 65–69, 2019.
[13] Zanghieri, M., et al. IEEE Trans. Biomed. Circuits Syst. 14(2), 244–256, 2020.
[14] Shen, Y., et al. arXiv:1811.07774, 2018.